Rebuttal 整理

原文：

Layer-Adaptive Visual Reinforcement for Vision-Language Navigation

Anonymous submission

Abstract

Vision-Language Navigation (VLN) requires embodied agents to navigate complex environments by grounding natural-language instructions in visual observations. However, effectively leveraging visual information throughout reasoning remains challenging. Our empirical analysis reveals that visual information is progressively attenuated as it propagates through deeper LLM layers, potentially limiting the model's ability to maintain effective visual grounding for navigation decision-making. Moreover, visual information also exhibits heterogeneous effects across different LLM layers. Strengthening visual representations at certain layers can enhance navigation reasoning, whereas reinforcing them at other layers may introduce perturbative signals that impair decision-making. Motivated by these observations, we propose Layer-Adaptive Visual Reinforcement (LAVR), a training-light mechanism that adaptively reconditions visual representations across multimodal decoder layers. Specifically, LAVR first evaluates each decoder layer in terms of both its need for visual reinforcement and the corresponding injection strength. A shared gated adapter then combines these signals to select a compact set of well-spaced layers. It further aligns the encoded visual features with the layer-wise hidden representations and adaptively integrates them into the selected layers. Experiments across multiple VLN architectures show that LAVR consistently improves closed-loop navigation performance and exhibits strong transferability, highlighting the importance of modeling layer-wise visual demands for more adaptive and effective visual information utilization in embodied decision-making. Code will be released to ensure full reproducibility.

Introduction

Vision-Language Navigation (VLN) is a fundamental task in embodied intelligence (Anderson et al. 2018b), requiring agents to follow natural-language instructions and make long-horizon navigation decisions from sequential visual observations. Existing VLN methods improve navigation decision-making by modeling visual observations and environmental context from different perspectives (Gu et al. 2022). One line of work (Zhang et al. 2024, 2025a; Qiao et al. 2022) directly reasons over 2D egocentric observations, projecting visual features into the language embedding space and jointly modeling them with instructions, trajectory histories, and candidate actions for action prediction. Some other works (Chen et al. 2022; Wang et al. 2023, 2021) augment these observations with topological graphs, online maps, or external memory to maintain global environmental context and support long-horizon planning. More recently, geometry-aware methods (Liu, Wang, and Yang 2024; Liu et al. 2023; Yang et al. 2026) explicitly reconstruct spatial structures using 3D scene representations or bird's-eye-view (BEV) maps, providing stronger spatial priors for navigation.

Despite these advances, existing studies have primarily focused on improving the visual observations provided to VLN agents, such as enhancing egocentric representations, incorporating global environmental context, or constructing explicit spatial structures. In other words, these methods mainly operate on the *observation vision* component in Figure 1(a), enriching or refining the visual information before it is fed into the multimodal decoder. In contrast, considerably less

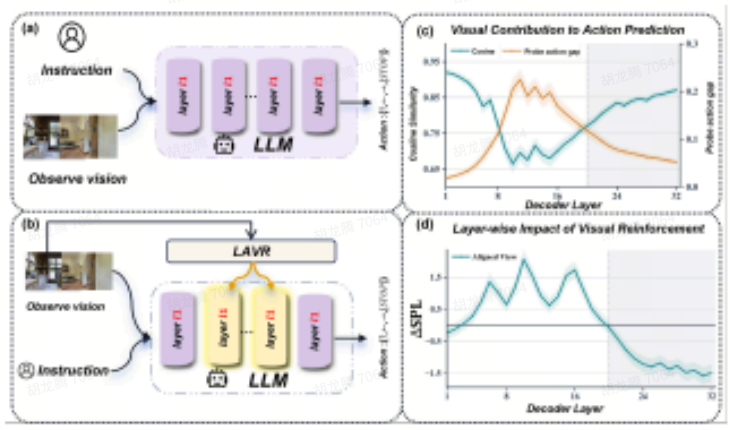


Figure 1: **Motivation of LAVR.** (a) A conventional VLN model processes visual observations and instructions through the multimodal decoder for action prediction. (b) LAVR adaptively reinforces visual representations at selected decoder layers. (c) Visual Contribution to Action Prediction analyzes how visual information contributes to navigation decisions across decoder depth. (d) Layer-wise Impact of Visual Reinforcement evaluates the navigation performance change caused by reinforcing visual information at different layers.

This is an anonymized submission for review purposes only. Distribution, citation, or public sharing of this manuscript is strictly prohibited. Copyright and publication details will appear in the final version if accepted.

36712_Layer_Adaptive_Visual_Re.pdf

第一个观察：视觉信息的影响似乎随深度减弱。

你用同一个视觉观察 v 和一个扰动后的视觉观察 $\tilde{v}$，保持指令、历史和候选动作不变，然后比较两种输入在不同层产生的隐藏状态和动作分布。

如果某一层仍然保留了较多视觉信息，那么原始输入和扰动输入应该产生明显不同的表示；如果两者越来越相似，就说明该层对视觉扰动越来越不敏感。

论文使用：

- 隐藏状态之间的余弦相似度；
- action probe 输出之间的 KL 散度。

你的论文观察到：早期层对扰动更敏感，深层的隐藏状态和动作分布更加相似。因此论文把它解释为：

> 视觉信息在向深层传播时逐渐衰减。

但这里也是审稿人最集中的质疑点：这些指标直接证明的是"对特定扰动的敏感性下降"，还不能完全证明"任务相关视觉信息丢失"。深层可能只是把视觉信息转换成了更抽象、更任务相关的表示。

第二个观察：不同层接受额外视觉信息的效果不同。

你把编码后的视觉特征只注入某一个 decoder layer，然后测量 SPL 相比原始模型的变化。

观察结果是：

- 某些早期和中间层注入后，SPL 提高；
- 某些层几乎没有收益；
- 大约第 20 层之后，注入反而可能降低 SPL；
- 这些有益层不是均匀分布的，而是呈现多个峰值。

于是论文提出：

> 不能把视觉信息均匀注入所有层，而应该找到真正需要额外视觉支持的层。

LAVR 主要包含三个部分：

1. VNA：Visual Necessity Assessment

   为每一层学习一个必要性分数 m_l，回答：

   > 这一层是否需要视觉强化?

2. ISE：Injection Strength Estimation

   计算当前层视觉表示和原始投影视觉特征之间的差异 d_l，回答：

   > 这一层的视觉表示偏离原始视觉特征多少?

3. GVA：Gated Visual Adapter

   将两个分数结合：

$$q_l = m_l d_l$$

再根据阈值、层预算和最小层间隔选择少数层，并通过 gated residual connection 注入视觉特征。

所以论文的理想逻辑是：

$$\text{VNA 判断“要不要补”} + \text{ISE 判断“偏离多少”} \rightarrow \text{GVA 决定在哪里强化}$$

Review1：（10月19号）5/4

Promising Navigation Improvements with Methodological and Experimental Concerns

Official Review by Program Committee dNwp 19 Oct 2026, 11:04 (modified: 24 Oct 2026, 20:28)

Program Chairs, Area Chairs, Senior Program Committee, Program Committee dNwp, Authors, Program Committee Submitted Revisions

Paper Summary:

This paper proposes Layer-Adaptive Visual Reinforcement (LAVR) to address visual information attenuation in vision-language navigation. The method combines Visual Necessity Assessment (VNA), Injection Strength Estimation (ISE), and a Gated Visual Adapter (GVA) to selectively reinforce visual representations at decoder layers. A two-stage training strategy is introduced to optimize the additional components while keeping the host model frozen. Experiments on R2R-CE and RxR-CE demonstrate consistent navigation improvements across three host architectures, supported by ablation studies and sensitivity analyses.

Strengths:

1. The analysis of visual information attenuation and heterogeneous layer-wise effects provides meaningful motivation for the proposed method.
2. The combination of layer necessity, representation discrepancy, and sparse reinforcement offers a simple and modular approach.
3. Consistent improvements across three VLN architectures and two benchmarks demonstrate the effectiveness and transferability of LAVR.
4. The ablation studies and sensitivity analyses provide useful experimental evidence, with relatively limited parameter and inference overhead.

Weaknesses:

1. The evidence for visual information attenuation is not fully convincing. Increasing hidden-state similarity and decreasing action-probe sensitivity may reflect normal representation transformations rather than the loss of task-relevant visual information. Its connection to navigation failures remains unclear.
2. The adaptivity of LAVR appears limited. Visual necessity relies on globally learned layer-wise parameters, while removing ISE only reduces SPL from 58.68 to 58.26, raising questions about its practical contribution.
3. The training and inference mechanisms are not fully aligned. Necessity scores are learned under dense reinforcement, whereas inference applies hard thresholding and sparse layer selection. The impact of this discrepancy remains unclear.
4. The experiments do not fully isolate the benefits of adaptive reinforcement. Gaussian noise and shuffled visual features also improve performance, suggesting that some gains may stem from residual interventions. Comparisons with simpler injection strategies are needed.
5. The generalizability of layer selection remains insufficiently validated. The first-20-layer restriction and separated injection pattern are motivated by observations from one model, with limited evidence supporting their applicability across architectures.
6. The role of ISE in controlling injection strength is unclear. Its output primarily affects layer selection rather than injection magnitude, raising questions about whether it truly estimates adaptive reinforcement strength.

Justification of Recommendation:

The paper addresses an interesting problem in vision-language navigation and reports consistent improvements across multiple architectures and benchmarks. However, several concerns limit my confidence in the proposed approach. The evidence for visual information attenuation does not fully establish the underlying motivation, and the contribution of the adaptive components appears relatively modest in the ablation results. Furthermore, the discrepancy between training and inference, together with the improvements obtained using perturbed visual features, raises questions about what actually drives performance gains. While the method is practically useful, stronger evidence is needed to establish its methodological novelty and the necessity of its core design choices.

Specific Points of Feedback for Rebuttal:

1. The authors should clarify why the observed attenuation indicates actual loss of task-relevant visual information rather than normal representation transformations. Stronger evidence connecting this phenomenon to navigation performance would be valuable.
2. The advantages of adaptive layer selection over simpler strategies need further justification. In particular, the globally learned necessity scores and the relatively small improvement introduced by ISE raises questions about the contribution of the adaptive mechanism.
3. The authors should clarify how the discrepancy between dense reinforcement during training and sparse selection during inference affects the reliability of layer selection.
4. The improvements obtained with Gaussian noise and shuffled visual features deserve further explanation, as they suggest that part of the gains may arise from residual interventions rather than meaningful visual reinforcement.
5. The generalizability of the first-20-layer restriction and separated injection pattern across different architectures requires further validation.
6. The authors should clarify why ISE is described as estimating reinforcement strength when its output primarily influences layer selection rather than directly controlling the injected visual information. Further justification of its role in adaptive reinforcement would strengthen methodological clarity.

Rating: 5: Marginally below acceptance threshold

Confidence: 4: The reviewer is confident but not absolutely certain that the evaluation is correct

Add: **Author Response**

原文翻译

1 评审原文完整翻译

2 标题：**导航性能提升可观，但方法设计与实验存在疑点** 官方评审 | 评审人：程序委员会 dNwp 2026年10月19日 11:04（修改时间：2026年10月24日 20:28） 收件人：程序主席、领域主席、高级程序委员会、PC成员dNwp、作者、程序委员会 提交链接：https://openreview.net/revisions?id=UMhpqdHxlg

论文摘要

本文提出层自适应视觉强化方法（Layer-Adaptive Visual Reinforcement，LAVR），用于解决视觉语言导航任务中的视觉信息衰减问题。该方法融合**视觉必要性评估（VNA）、注入强度估计（ISE）、门控视觉适配器（GVA）**，在解码器层对视觉表征进行选择性增强；同时设计两阶段训练策略，在冻结宿主主干模型的前提下优化新增模块。 在R2R-CE、RxR-CE数据集上，本文在三种宿主架构下均取得稳定导航性能提升，并配套消融实验与敏感性分析佐证效果。

优点

针对视觉信息衰减、不同层级表征差异化效应的分析，为本方法提供了有价值的研究动机。

结合层级必要性、表征差异与稀疏增强的设计，方案简洁、模块化程度高。

在三套VLN架构、两个基准数据集上均取得稳定增益，证明LAVR有效且具备迁移能力。

消融实验与敏感性分析提供了有效的实验支撑；新增参数量与推理开销都比较小。

缺点

视觉信息衰减的论证证据说服力不足：隐状态相似度上升、动作探针敏感度下降，这一现象有可能只是表征的正常变换，而不是任务相关视觉信息发生丢失；该现象和导航失败之间的因果关系尚不明确。

LAVR的自适应能力比较有限：视觉必要性评估依赖全局学习得到的层级参数；去掉ISE模块后，SPL仅从58.68下降到58.26，让人怀疑ISE的实际贡献。

训练与推理机制不一致：必要性分数是在稠密增强的训练模式下学习得到，但推理阶段使用硬阈值、稀疏层级选择。这种不一致带来的影响尚不清晰。

实验没能完全隔离自适应增强带来的收益：高斯噪声、打乱视觉特征的基线同样可以提升性能，说明一部分性能增益可能仅仅来自残差扰动。需要和更简单的注入策略做对比。

层级选择策略的泛化性验证不足：前20层限制、分离式注入模式，都只是基于单个模型的观察提出；缺少足够证据证明这套规则在其他架构上同样适用。

ISE控制注入强度的作用存疑：ISE的输出主要用来影响层级选择，而不是直接控制注入表征的幅值；让人质疑它是否真的在估计自适应增强的强度。

推荐意见说明

本文瞄准视觉语言导航里一个有意思的问题，并且在多个架构、多个基准上都观测到稳定性能提升。但是上面多处疑点降低了我对该方法的认可度： 视觉衰减的证据不足以支撑论文核心动机；消融结果显示自适应组件带来的增益比较微弱；训练推理不一致、加噪声也能涨点这两点，让人怀疑真正驱动性能提升的因素到底是什么。 该方法本身有一定实用价值，但还需要更强的实验证据，来证明方法的创新性、以及核心设计的必要性。

给作者的Rebuttal专项反馈点

作者需要说明：你观测到的衰减现象，为什么代表**任务相关视觉信息真的丢失了**，而不只是表征正常变换；最好补充更强证据，把这个现象和导航性能直接关联起来。

需要进一步论证：相比于更简单的策略，自适应层级选择的优势在哪里。尤其是全局学习的必要性分数、ISE带来的指标提升幅度很小这两点，会让人质疑自适应机制本身的价值。

请解释清楚：训练时稠密增强、推理时稀疏选择，这种不一致会对层级选择的可靠性造成什么影响。

高斯噪声、打乱特征也能涨点这个现象需要重点解释：这说明部分增益可能来自残差扰动，而不是有意义的视觉信息增强。

“仅前20层生效”的限制、分离式注入模式，在不同架构上的泛化性需要补充验证。

ISE被描述为估计增强强度，但是它的输出主要用来选层，并不直接控制注入的视觉信息幅值，请作者对此做出解释；补充论证它在自适应增强流程里的作用，提升方法逻辑清晰度。

打分与置信度

评分：**5分：略低于录用线（Marginally below acceptance threshold）** 置信度：4分：评审人比较有把握，但不能百分百保证本次评估完全准确

缩写备查（写rebuttal直接用）

主要任务的缺点：

1. **视觉信息衰减的论证证据说服力不足**：隐状态相似度上升、动作探针敏感度下降，这一现象有可能只是表征的正常变换，而不是任务相关视觉信息发生丢失；该现象和导航失败之间的因果关系尚不明确。（视觉减弱的问题质疑）
2. **LAVR 的自适应能力比较有限**：视觉必要性评估依赖全局学习得到的层级参数；去掉 ISE 模块后，SPL 仅从 58.68 下降到 58.26，让人怀疑 ISE 的实际贡献。

VNA：哪一层通常适合强化

ISE：当前样本在哪些层偏离更大

GVA：根据二者决定当前样本在哪些层注入

ISE 的价值不是一定要带来很大的平均 SPL 增益，而是让固定的层级先验变成状态相关的层选择。

若这么回答需要补充下面的实验

VNA-only 和完整 LAVR 选择了哪些层；

两者的层选择重合率；

不同导航 step 中 d_l 是否发生变化；

高 d_l 的层是否更容易被选中；

选中层和未选中层的单层注入收益是否不同。

第二种路线是修改公式，让 ISE 真正控制注入幅度。

例如可以将公式（9）改成：

$$\tilde{H}_l^V = H_l^V + z_l \alpha_l R^V$$

其中：

$$\alpha_l = d_l$$

或者：

$$\alpha_l = q_l = m_l d_l$$

更自然的版本是：

$$\tilde{H}_l^V = H_l^V + z_l m_l d_l R^V$$

3. **训练与推理机制不一致**：必要性分数是在稠密增强的训练模式下学习得到，但推理阶段使用硬阈值、稀疏层级选择。这种不一致带来的影响尚不清晰。
4. **实验没能完全隔离自适应增强带来的收益**：高斯噪声、打乱视觉特征的基线同样可以提升性能，说明一部分性能增益可能仅仅来自残差扰动。需要和更简单的注入策略做对比。
5. **层级选择策略的泛化性验证不足**：前 20 层限制、分离式注入模式，都只是基于单个模型的观察提出；缺少足够证据证明这套规则在其他架构上同样适用。**（在额外的其他的模型进行补充，将来会在revise上加上其他模型的图）**
6. **ISE 控制注入强度的作用存疑**：ISE 的输出主要用来影响层级选择，而不是直接控制注入表征的幅值；让人质疑它是否真的在估计自适应增强的强度。

需要回复：

- “视觉信息衰减”是否真的等于任务相关视觉信息丢失；
- 去掉 ISE 后只下降 0.42 SPL，ISE 的实际贡献是否足够；
- 训练时密集注入、推理时稀疏选择，二者是否一致；
- 加噪声、打乱特征也能提升，是否说明普通残差干预就足够；
- 前 20 层限制和层间隔规则能否泛化到其他架构；
- ISE 被称为“注入强度”，但实际上主要用于选层，定义是否合理。

他的本质问题是：

你能否证明 LAVR 的完整自适应设计，而不是简单的中间层残差注入，才是性能提升的主要来源？

Review2：（10月18号）6/4

LAVR review

Official Review by Program Committee 1w4W 18 Oct 2026, 01:03 (modified: 24 Oct 2026, 20:28)

Program Chairs, Area Chairs, Senior Program Committee, Program Committee 1w4W, Authors, Program Committee Submitted Revisions

Paper Summary:
The paper introduces LAVR, a lightweight method that selectively reinjects visual features into vision-language navigation models. The authors investigate visual information appears to become less influential in deeper decoder layers, and reinforcing visual representations at different layers produces effects on navigation performance. They show that additional visual information can improve performance at some layers while degrading it at others. The work uses 3 components: VNA, ISE, GVA. They evaluate on navigation benchmarks R2R-CE, RxR-CE across three architectures UniNaVid, StreamVLN, GAVLN show improvements without extensive backbone fine-tuning.

Strengths:
The paper's strengths are its empirically motivated design, and lightweight implementation. It checks how visual information influences decisions within the decoder, complementing approaches that focus on improving visual inputs. Its does selective reinforcement, to avoid poorly placed visual interventions that can lower performance. LAVR works with frozen backbones and shows improvements across three architectures and two benchmarks. Component ablations support the usefulness of its selection signals and two-stage training.

Weaknesses:
The paper have the following weakness and paths for improvement: Deeper layers usually encode visual information more abstractly or integrate it with other context. Thus, reduced sensitivity based on cosine similarity and KL divergence doesn't prove information loss. It only supports the narrower claim that measured sensitivity decreases with depth. Suggests clarifying what's being measured and using controlled probes. The method combines a learnable necessity score with a discrepancy score for selecting layers. But large discrepancy doesn't necessarily mean a layer needs more data and it doesn't guarantee the layers get selected at inference. The improvement would be adding a report of score distributions, actual selected-layer counts, and comparing against simpler selection rules. LAVR improves performance, but it shows injecting Gaussian noise or shuffled features at selected layers also improves over no-injection. So it's unclear how much gain comes from which layers are selected versus the general effect of adding a residual signal.

Justification of Recommendation:
The paper is well presented and shows improvements upon other methods. But the paper doesnt provide enough evidence that visual information is actually being lost and the benefit of adaptive layer selection isn't isolated from simpler injection strategies. Thus, the score could be higher if additional validation is presented.

Specific Points of Feedback for Rebuttal:
Could they clarify why the observed trends imply that useful visual information is being lost, rather than transformed or integrated into more abstract representations? A concise explanation of the metrics and the relevant observations would help establish the interpretation underlying the method

Could the authors clarify whether they have results for random or fixed-layer injection using the same number of layers and comparable injection magnitudes? Reporting them would help determine whether LAVR's adaptive selection provides benefits beyond additional intermediate-layer injection.

Rating: 6: Marginally above acceptance threshold
Confidence: 4: The reviewer is confident but not absolutely certain that the evaluation is correct

Add: **Author Response**

原文翻译

评审全文翻译
官方评审 | 评审人：程序委员会 1w4W 2026 年 10 月 18 日 01:03（修改时间：2026-10-24 20:28） 收件对象：程序主席、领域主席、高级程序委员会、PC 成员 1w4W、作者、程序委员会
论文摘要
本文提出 LAVR，一种轻量化方法，用于向视觉语言导航模型中有选择地重新注入视觉特征。作者研究发现：在解码器更深层中，视觉信息的影响力似乎会下降；在不同层级对视觉表征做增强，会对导航性能产生不同影响。实验表明，在某些层级补充视觉信息能够提升性能，但在另一些层级反而会造成性能下降。本工作由 VNA、ISE、GVA 三个模块组成；在 R2R-CE、RxR-CE 两大导航基准上，基于 UniNav、StreamVLN、GA-VLN 三种架构开展评测，**全程不对主干网络做大规模微调**即可取得性能提升。
优点
本文的亮点在于基于实证观察提出设计方案，并且实现轻量化。文章探究了视觉信息如何在解码器内部影响决策，和那些聚焦于优化视觉输入的相关工作形成互补。方法采用选择性增强机制，避免因不合适的视觉干预拉低模型性能。 LAVR 可以在主干冻结的条件下工作，并且在三种架构、两个数据集上都取得提升；组件消融实验也验证了选择信号以及两阶段训练方案的有效性。
缺点
本文存在如下缺陷与改进方向： 深层通常会把视觉信息编码成更抽象的形式，或是将视觉信息和其他上下文融合在一起。因此，基于余弦相似度、KL 散度得到的 “敏感度下降”**不能证明信息发生了丢失**，仅能说明：测量得到的敏感度随网络深度增加而降低。建议明确测量对象，并设计受控探针实验。 该方法结合可学习必要性分数与差异分数来选择层级。但是，表征差异大，并不代表该层就需要补充视觉数据，也无法保证推理时选中的层是合适的。 如果补充分数分布统计、实际被选中层的数量统计，并和更简单的选择规则做对比，会更有说服力。 LAVR 能够提升性能，但实验发现：在选定层注入高斯噪声、打乱后的特征，对比完全不注入的基线同样可以涨点。因此目前无法分清：性能增益到底来自选中特定层级带来的收益，还是单纯增加残差信号带来的通用效应。
推荐理由
论文行文清晰，相比其他方法取得了性能提升。但是文章没有提供充分证据证明视觉信息确实发生丢失；同时自适应层级选择带来的收益，无法和简单注入策略区分开。如果补充更多验证实验，本论文打分还有上升空间。
Rebuttal 专项反馈点
能否解释清楚：你观测到的趋势为什么代表有用视觉信息丢失，而不是信息被变换、融合成了更抽象的表征？对评价指标与对应观测结果给出简洁解释，有助于支撑本方法背后的核心解读逻辑。
作者是否做过**同等层数、同等注入幅值条件下，随机选层 / 固定层注入**的对照实验？汇报这组结果，有助于判断：LAVR 自适应选择带来的收益，是否超越了 “单纯在中间层加注入” 这个基础操作本身。
打分与置信度
评分：**6 分：略高于录用线（Marginally above acceptance threshold）** 置信度：4 分：评审人比较有把握，但不能百分百保证本次评估完全准确

缺点：

- 层通常会把视觉信息编码成更抽象的形式，或是将视觉信息和其他上下文融合在一起。因此，基于余弦相似度、KL 散度得到的“敏感度下降”**不能证明信息发生了丢失**，仅能说明：**测量得到的敏感度随网络深度增加而降低。**建议明确测量对象，并设计受控探针实验。 该方法结合可学习必要性分数与差异分数来选择层级。**但是，表征差异大，并不代表该层就需要补充视觉数据，也无法保证推理时选中的层是合适的。**
- 如果补充分数分布统计、实际被选中层的数量统计，并和更简单的选择规则做对比，会更有说服力。 LAVR 能够提升性能，**但实验发现：在选定层注入高斯噪声、打乱后的特征，对比完全不注入的基线同样可以涨点。因此目前无法分清：性能增益到底来自选中特定层级带来的收益，还是单纯增加残差信号带来的通用效应。**

Rebuttal的点：

1.1 能否解释清楚：*你观测到的趋势为什么代表有用视觉信息丢失，而不是信息被变换、融合成了更抽象的表征？对评价指标与对应观测结果给出简洁解释，有助于支撑本方法背后的核心解读逻辑。*
（敏感性下降不一定代表视觉信息丢失，也可能是视觉信息被抽象化或融合了；）

1.2 作者是否做过同等层数、同等注入幅值条件下，随机选层 / 固定层注入的对照实验？汇报这组结果，有助于判断：LAVR 自适应选择带来的收益，是否超越了 “单纯在中间层加注入” 这个基础操作本身。
（需要提供相同注入层数、相同注入幅度下的随机层、固定层或简单规则层选择结果。）

Review3：（10月7号） 4/4

Reviews of Submission36712

Official Review by Program Committee HLC3 07 Oct 2026, 11:29 (modified: 24 Oct 2026, 20:28)

Program Chairs, Area Chairs, Senior Program Committee, Program Committee HLC3, Authors, Program Committee Submitted Revisions

Paper Summary:
The idea is promising and the empirical gains are encouraging, but the current manuscript over-interprets several empirical observations as mechanisms. Tightening the formulation and adding targeted causal controls would substantially strengthen the work.

Strengths:
The paper studies a meaningful and relatively underexplored question: instead of only improving the visual representations fed into a VLN agent, it investigates how visual information evolves inside the multimodal decoder and selectively reinforces visual features at particular decoder layers. The reported improvements across three host architectures are encouraging.

Weaknesses:
1. ISE does not actually control the injection strength: The terminology and formulation of ISE appear inconsistent. d_l is introduced as an estimate of the required injection strength, yet Eq. (9) uses m_l, rather than d_l or $q_l = m_l d_l$, to scale the injected visual representation. Thus, d_l affects layer selection but apparently not the amount of visual information injected. This weakens the central claim that LAVR jointly determines “where” and “how much” visual reinforcement is needed. The authors should either revise the terminology or directly use d_l in the residual injection and provide corresponding ablations.

2. Feature discrepancy is not equivalent to visual information loss: The proposed normalized Frobenius distance measures representational deviation from the initial projected visual tokens, but such deviation does not necessarily indicate visual forgetting. Deeper decoder states are expected to become increasingly task-specific and cross-modally integrated. A representation can therefore move far away from the original visual embedding while still retaining, or even better encoding, task-relevant visual information. The paper would be considerably stronger if it established a correlation between d_l and an independent measure of visual grounding or visual decodability.

3. Reduced perturbation sensitivity is not sufficient evidence of “visual attenuation”: The evidence for “visual information attenuation” is currently indirect. Increased hidden-state similarity under visual perturbations may reflect invariance or task-relevant abstraction rather than forgetting. In addition, the nature and severity of the visual perturbation are crucial but insufficiently specified. The action-probe analysis also requires considerably more methodological detail. I recommend softening the claim from “visual information is attenuated” to “sensitivity to the chosen visual perturbation decreases with depth” unless stronger information-preservation evidence is provided.

Justification of Recommendation:
See above.

Specific Points of Feedback for Rebuttal:
See Weakness.

Rating: 4: Ok but not good enough - rejection
Confidence: 4: The reviewer is confident but not absolutely certain that the evaluation is correct

Add: **Author Response**

翻译

```
对投稿 36712 的评审
正式评审
评审人：Program Committee HLC3
日期：2026 年 10 月 7 日
论文总结
这个想法很有前景，实验结果也令人鼓舞，但当前稿件将若干经验观察过度解释成了机制。进一步收紧论文表述，并加入有针对性的因果控制实验，将显著增强这项工作。
优点
```

本文研究了一个有意义且相对较少被探索的问题：论文不只是改进输入 VLN agent 的视觉表示，而是研究视觉信息如何在多模态解码器内部演化，并在特定 decoder layer 处选择性地强化视觉特征。论文在三种 host architecture 上报告的改进结果令人鼓舞。
缺点
1. ISE 实际上并不控制注入强度
ISE 的术语和公式表述似乎不一致。论文将 \(d_l\) 定义为所需注入强度的估计值，但公式（9）使用的是 \(m_l\)，而不是 \(d_l\) 或 \(q_l=m_ld_l\)，来缩放注入的视觉表示。
因此，\(d_l\) 会影响层选择，但似乎不会影响注入的视觉信息量。这削弱了 LAVR 同时决定“在哪些层”以及“需要多少”视觉强化这一核心论断。
作者应当重新审视相关术语，或者直接在残差注入中使用 \(d_l\)，并提供相应的消融实验。
2. 特征差异不等价于视觉信息丢失
论文提出的归一化 Frobenius 距离衡量的是当前表示相对于初始投影视觉 token 的偏离程度，但这种偏离并不一定表示发生了视觉遗忘。
更深层的 decoder state 理论上会变得越来越具有任务特异性，并与跨模态信息进行整合。因此，一个表示可以远离原始视觉 embedding，同时仍然保留任务相关的视觉信息，甚至形成更好的任务相关编码。
如果论文能够建立 \(d_l\) 与某种独立的视觉 grounding 或视觉可解码性指标之间的相关性，论文会明显更有说服力。
3. 扰动敏感性降低不足以证明“视觉衰减”
当前关于“视觉信息衰减”的证据是间接的。在视觉扰动下，隐藏状态相似度升高可能反映的是模型不变性，或者任务相关的抽象化，而不是信息遗忘。
此外，视觉扰动的性质和强度非常关键，但论文目前说明得不够充分。action-probe 分析也需要更多方法细节。
我建议作者将论文中的表述从：
弱化为：
除非作者能够提供更强的信息保留证据。
推荐意见说明
见上述缺点。
Rebuttal 的具体反馈
见上述缺点。
评分：4：可以，但还不够好—拒稿
置信度：4：审稿人比较确信，但不能绝对确定该评价正确
底部的 **“Add: Author Response”** 是评审系统中的回复按钮，不属于审稿意见本身。

缺点：

ISE 实际上并不控制注入强度

ISE 的术语和公式表述似乎不一致。论文将 d_l 定义为所需注入强度的估计值，但公式（9）使用的是 m_l，而不是 d_l 或 $q_l = m_l d_l$，来缩放注入的视觉表示。

因此，d_l 会影响层选择，但似乎不会影响注入的视觉信息量。这削弱了 LAVR 同时决定“在哪些层”以及“需要多少”视觉强化这一核心论断。

作者应当重新审视相关术语，或者直接在残差注入中使用 d_l，并提供相应的消融实验。
（d_l 被定义为注入强度，但公式（9）实际用 m_l 控制注入幅度；
d_l 只影响 $q_l = m_l d_l$，因此主要影响“选不选这一层”，而不直接影响“注入多少”；）

特征差异不等价于视觉信息丢失（表征偏差不等于视觉信息丢失；）

论文提出的归一化 Frobenius 距离衡量的是当前表示相对于初始投影视觉 token 的偏离程度，但这种偏离并不一定表示发生了视觉遗忘。

更深层的 decoder state 理论上会变得越来越具有任务特异性，并与跨模态信息进行整合。因此，一个表示可以远离原始视觉 embedding，同时仍然保留任务相关的视觉信息，甚至形成更好的任务相关编码。

如果论文能够建立 d_l 与某种独立的视觉 grounding 或视觉可解码性指标之间的相关性，论文会明显更有说服力。

扰动敏感性降低不足以证明“视觉衰减”（对扰动敏感性下降也不足以证明视觉衰减。）

当前关于“视觉信息衰减”的证据是间接的。在视觉扰动下，隐藏状态相似度升高可能反映的是模型不变性，或者任务相关的抽象化，而不是信息遗忘。

此外，视觉扰动的性质和强度非常关键，但论文目前说明得不够充分。action-probe 分析也需要更多方法细节。

我建议作者将论文中的表述从：

> “视觉信息正在衰减”

弱化为：

> “模型对所选视觉扰动的敏感性会随着深度增加而降低”

除非作者能够提供更强的信息保留证据。

感谢审稿人

对视觉信息的利用下降，敏感度也会下降，修改表述

Review 4 （9月1号） 6/3

Review

Official Review by Program Committee 73Lo 01 Sept 2026, 15:35 (modified: 24 Oct 2026, 20:28)

Program Chairs, Area Chairs, Senior Program Committee, Program Committee 73Lo, Authors, Program Committee Submitted Revisions

Paper Summary:
This paper proposes LAVR, Layer-Adaptive Visual Reinforcement Learning for VLN. This paper studies how different layers in MLLM latent space influence the model in decision-making for VLN. This paper proposes an approach that first evaluates each decoder layer in terms of both its need for visual reinforcement and the corresponding injection strength. A shared gated adapter then combines these signals to select a compact set of well-spaced layers. It further aligns the encoded visual features with the layer-wise hidden representations and adaptively integrates them into the selected layers. Empirically, on the continuous navigation benchmark, the proposed approach demonstrated superior performance compared to different base models.

Strengths:
1. Rather than only changing maps, observations, visual encoders, or spatial representations, it studies what happens to already-encoded visual evidence inside the multimodal decoder. This paper connects layer-level representation behavior to the action distribution and ultimately to navigation SPL, which is more meaningful for VLN than demonstrating only representation similarity.
2. The proposed components Visual Necessity Assessment (VNA), Injection Strength Estimation (ISE), and Gated Visual Adapter (GVA), align the encoded visual features with the corresponding hidden space and integrate them through a gated residual connection.
3. Experiments on R2R-CE and RxR-CE benchmarks demonstrate the effectiveness of the proposed approach.
4. This paper is well-written and easy to follow.

Weaknesses:
1. More benchmarks should be tested for the proposed approach (e.g., discrete navigation benchmarks like R2R and RxR). This will helps demonstrate the generalization of the approach to different setup.
2. More discussion about why shuffled view / noise also helps improve the performance instead of harm the performance compared to baseline (Table2). This seems to be an indication that the model is not learning well from the visual representation so shuffled view / noise doesn't lead to model failure.
3. Only val-unseen performance is provided, test-unseen performance is missing in Table 1.

Justification of Recommendation:
Please refer to strengths/weakness.

Specific Points of Feedback for Rebuttal:
N/A

Rating: 6: Marginally above acceptance threshold
Confidence: 3: The reviewer is fairly confident that the evaluation is correct

Add: **Author Response**

代码块

```
评审全文翻译
官方评审 | 评审人：程序委员会 73Lo 2026 年 09 月 01 日 15:35（修改时间：2026-10-24 20:28） 收件对象：程序主席、领域主席、高级程序委员会、PC 成员 73Lo、作者、程序委员会 链接：https://openreview.net/revisions?id=paKd0SLb3x
论文摘要
本文提出 LAVR，即面向视觉语言导航（VLN）的层自适应视觉强化方法。文章探究多模态大模型隐空间中不同层级，会如何影响模型在 VLN 任务里的决策过程。本文所提方法首先对解码器每一层做两项评估：该层是否需要视觉增强、以及对应的注入强度；随后利用一个共享门控适配器，融合上述信号，选出一组数量精简、间隔分布合理的层级。该方法还会把编码后的视觉特征和各层隐表征做对齐，自适应地将视觉特征融合进被选中的层级。在连续导航基准任务上的实验表明，相比于多个基础模型，本方法取得更优性能。
优点
本工作没有局限于修改观测图、视觉编码器或者空间表征，而是去研究已经编码完成的视觉证据在多模态解码器内部会发生什么变化。文章把层级层面的表征行为和动作分布、乃至导航指标 SPL 建立关联；相比单纯展示表征相似度的工作，这个思路对 VLN 任务更有研究价值。
本文提出视觉必要性评估（VNA）、注入强度估计（ISE）、门控视觉适配器（GVA）三个模块，将编码后的视觉特征对齐至对应隐空间，并通过门控残差连接完成融合。
在 R2R-CE、RxR-CE 基准上的实验验证了方法有效性。
论文行文流畅，可读性好。
```

缺点
应当在更多基准上测试该方法（例如 R2R、RxR 这类离散导航基准），以此证明该方法在不同任务设定下的泛化能力。
需要进一步讨论：为什么打乱视图 / 加入噪声的操作，相比基线**反而可以提升性能，而不是损害性能**（表 2 结果）。这个现象似乎说明：模型并没有很好地利用视觉表征学习，所以打乱视图、添加噪声也不会让模型直接失效。
表 1 只给出了 val-unseen（验证集 - 未见过环境）结果，缺少 test-unseen（测试集 - 未见过环境）的实验结果。
推荐意见说明
参考上述优点与缺点。
Rebuttal 专项反馈点
无（N/A）
打分与置信度
评分：**6 分：略高于录用线（Marginally above acceptance threshold）** 置信度：3 分：评审人有一定把握，认为本次评估结论基本成立

1. 应当在更多基准上测试该方法（例如 R2R、RxR 这类离散导航基准），以此证明该方法在不同任务设定下的泛化能力。（补充数据集实验结果）
2. 需要进一步讨论：为什么打乱视图 / 加入噪声的操作，相比基线**反而可以提升性能，而不是损害性能**（表 2 结果）。这个现象似乎说明：模型并没有很好地利用视觉表征学习，所以打乱视图、添加噪声也不会让模型直接失效。

你的 LAVR 在选定层做的是：

$$\tilde{H}_l^V = H_l^V + z_l m_l R^V$$

也就是把经过 projector 对齐后的视觉残差加回当前层的视觉 token hidden states。后续 decoder layer 再把这个视觉残差和 instruction、navigation history、candidate actions 结合起来。

因此，注入效果可以分成两部分：

$$\text{总收益} = \text{合适注入位置带来的收益} + \text{注入内容质量带来的收益}$$

解释的思路：

选定层原本可能存在视觉条件不足或视觉表征过度压缩的问题；

向这些层加入额外残差信号，可以重新激活或扰动视觉-语言状态；

因此，即使噪声或打乱特征也能带来一部分收益；

但只有保留正确视觉语义的 current-view feature，才能进一步改善导航决策。

3. 表 1 只给出了 val-unseen（验证集 - 未见过环境）结果，缺少 test-unseen（测试集 - 未见过环境）的实验结果（补充实验）

Review5（8月31号） 4/4：

Review of LAVR

Official Review by Program Committee aVNe 31 Aug 2026, 09:14 (modified: 24 Oct 2026, 20:28)

Program Chairs, Area Chairs, Senior Program Committee, Program Committee aVNe, Authors, Program Committee Submitted Revisions

Paper Summary:

This paper investigates the internal processing mechanism of visual information within LLM decoders for VLN tasks. The authors perform a layer-wise empirical analysis and reveals the visual information attenuation phenomena. Therefore, they propose layer-adaptive visual reinforcement (LAVR) which firstly assess whether the layer should be reinforced then inject the visual information bay a gated adapter. This method serves as a selective residual learning and the experiments proved its effectiveness on three chosen baselines.

Strengths:

1. This paper provides a novel and interesting perspective for analyzing LLM-based VLN models. It's important to understand how visual representations evolve across decoder layers during decision-making, rather than solely focusing on input visual feature engineering.
2. The proposed LAVR provides a parameter-efficient solution to enhance current LLM-based VLN models

Weaknesses:

1. In the introductory empirical analysis ("Motivating Observations"), the paper claims two core phenomena based on layer-wise analysis. However, it is unclear which specific VLN model was used to generate Figure 1 and Equations 1–2. Do these two phenomena (visual attenuation and multi-peak sensitivity) hold universally across different VLN backbones? The authors should specify the exact setup and present preliminary analysis on multiple architectures to substantiate the universality of these phenomena.
2. In Section Visual Information Attenuation, the authors introduce a perturbed visual observation to measure layer-wise sensitivity. However, the exact method and intensity of this perturbation are not explicitly described: a) What specific perturbation technique was applied (e.g., Gaussian noise, blacking out frames, feature-level masking, or semantic image modifications)?

b) How was the perturbation magnitude determined? c) Does the observed attenuation trend remain consistent under varying intensities or types of visual perturbations? Providing these details is essential for reproducibility and verifying the soundness of the empirical claims. 3. As shown in Equation 1 and Figure 1(c) (or Section Visual Information Attenuation), the authors measure the cosine similarity between hidden states generated from clean visual information and perturbed visual information. Theoretically, a strong visual perturbation should cause early decoder layers to produce significantly different visual representations, resulting in a lower cosine similarity. However, Figure 1 shows that even in the very early layers, the cosine similarity remains quite high. The authors should offer a detailed explanation for why early-layer representations remain relatively similar despite visual perturbations and clarify what constitutes a "significant" drop in similarity in this context. 4. In Section Layer-wise Visual Impact, the single-layer visual injection analysis evaluates performance changes using SPL. While SPL is a standard VLN metric, why was SPL chosen instead of using Success Rate (SR) or Navigation Error (NE) for this diagnostic intervention? To ensure the findings are robust, the paper should provide corresponding layer-wise analysis plots for SR and NE to confirm whether visual reinforcement directly improves target reachability or primarily affects path efficiency. 5. In Section Gated Visual Adapter, the authors hypothesize that newly injected visual features require several subsequent decoder layers to be absorbed and integrated before another injection occurs, motivating the minimum layer gap constraint. While Table 4 shows that removing the separation loss degrades performance, there is a lack of detailed ablation experiments on key parameters: a) How sensitive is the model to the exact value of the layer gap? b) How does the layer budget affect overall performance and computational trade-offs? c) What's the effect of the threshold τ ? 6. While Table 1 evaluates LAVR across three models (Uni-NaVid, StreamVLN, GA-VLN), the authors are encouraged to evaluate on additional recent or larger-scale VLN / VLA models (such as NaVILA or InternVLN-N1).

Justification of Recommendation:

The paper interprets the diminishing sensitivity to visual perturbations in deeper layers as problematic "visual attenuation" that harms navigation. However, maybe this layer-wise behavior could alternatively be viewed as a natural functional division learned by Transformer decoder: Early-to-intermediate layers may learned to process and extract visual observations, while deeper layers may learned to consolidate multi-modal representations into abstract, high-level action decisions. Therefore, simply showing that deeper layers are less sensitive to perturbed inputs does not inherently prove that "visual attenuation" is a flaw limiting navigation ability. The authors need to strengthen their logical reasoning and provide more concrete theoretical or empirical grounding to justify why re-injecting visual features into intermediate layers addresses a true failure mode rather than forcing unnatural visual conditioning onto decision-focused layers.

Specific Points of Feedback for Rebuttal:

See weaknesses.

Rating: 4: Ok but not good enough - rejection

Confidence: 4: The reviewer is confident but not absolutely certain that the evaluation is correct

Add: **Author Response**

翻译

LAVR 评审
正式评审
评审人：Program Committee aVNe
日期：2026 年 8 月 31 日
论文总结
本文研究 VLN 任务中，视觉信息在 LLM decoder 内部的处理机制。作者进行了逐层经验分析，并发现了视觉信息衰减现象。因此，作者提出了 Layer-Adaptive Visual Reinforcement（LAVR）：首先判断某一层是否需要强化，然后通过 gated adapter 注入视觉信息。
该方法可以被视为一种选择性的残差学习。实验结果证明，该方法在三个选定的 baseline 上有效。
优点
本文为分析基于 LLM 的 VLN 模型提供了新颖且有趣的视角。理解视觉表示在决策过程中如何跨 decoder layer 演化很重要，而不应只关注输入视觉特征工程。
LAVR 为增强现有基于 LLM 的 VLN 模型提供了一种参数高效的解决方案。
缺点
1. 动机分析所使用的具体模型不明确
在引言中的经验分析部分，即“Motivating Observations”，论文基于逐层分析提出了两个核心现象。然而，论文没有说明 Figure 1 和公式（1）–（2）具体使用了哪个 VLN 模型。
这两个现象，即视觉衰减和多峰敏感性，是否在不同 VLN backbone 上都普遍成立？作者应明确说明实验设置，并在多个架构上进行初步分析，以支持这些现象具有普遍性。
2. 视觉扰动的方法和强度没有明确描述
在“Visual Information Attenuation”部分，作者引入了一个受到扰动的视觉观察，用于测量逐层敏感性。然而，论文没有明确说明该扰动的具体方法和强度。
具体而言：
a）使用了哪种扰动技术？例如高斯噪声、将视频帧置黑、特征级 masking，还是语义图像修改？
b）扰动幅度是如何确定的？
c）当改变视觉扰动的强度或类型时，观察到的衰减趋势是否仍然一致？
提供这些细节对于保证实验可复现性、验证经验结论的可靠性非常重要。

3．早期层的余弦相似度仍然较高，需要进一步解释
如公式（1）和 Figure 1（c）（或“Visual Information Attenuation”部分）所示，作者测量了由干净视觉信息和扰动视觉信息产生的隐藏状态之间的余弦相似度。
从理论上讲，较强的视觉扰动应该使早期 decoder layer 产生明显不同的视觉表示，从而导致较低的余弦相似度。然而，Figure 1 显示，即使在非常早的层，余弦相似度仍然相当高。
作者应详细解释：为什么早期层的表示在受到视觉扰动后仍然保持较高相似度？在这一背景下，什么程度的相似度下降才可以被认为是“显著下降”？
4．为什么使用 SPL 而不是 SR 或 NE？
在“Layer-wise Visual Impact”部分，单层视觉注入实验使用 SPL 来评估性能变化。SPL 虽然是标准的 VLN 指标，但为什么在这一诊断性干预实验中选择 SPL，而不是 Success Rate（SR）或 Navigation Error（NE）？
为了确保结论更加稳健，论文应提供 SR 和 NE 的对应逐层分析图，以确认视觉强化究竟是直接改善了目标到达能力，还是主要影响了路径效率。
5．层间隔、层预算和阈值缺乏详细消融
在“Gated Visual Adapter”部分，作者假设新注入的视觉特征需要经过若干后续 decoder layer 才能被吸收和整合，然后才适合进行下一次注入。这一假设构成了最小层间隔约束的动机。
虽然 Table 4 表明移除 separation loss 会导致性能下降，但论文缺少对关键参数的详细消融实验：
a）模型对层间隔具体取值的敏感性如何？
b）layer budget 会如何影响整体性能以及计算开销之间的权衡？
c）阈值 \(\tau\) 的影响是什么？
此外，虽然 Table 1 在三个模型上评估了 LAVR，即 Uni-NaVid、StreamVLN 和 GA-VLN，但仍建议作者在更多近期的或更大规模的 VLN/VLA 模型上进行评估，例如 NaVILA 或 InternVL-N1。
推荐意见说明
论文将深层对视觉扰动的敏感性降低解释为一种会损害导航能力的“视觉衰减”。然而，这种逐层行为也可以被理解为 Transformer decoder 学习到的一种自然功能分工：
早期到中间层可能负责处理和提取视觉观察；
更深层可能负责将多模态表示整合为抽象的高层动作决策。
因此，仅仅证明深层对扰动输入更加不敏感，并不能直接证明“视觉衰减”是限制导航能力的缺陷。
作者需要加强逻辑论证，并提供更具体的理论或经验依据，以说明为什么将视觉特征重新注入中间层是在解决真实的失败模式，而不是将不自然的视觉条件强行加入主要负责决策的层。
Rebuttal 的具体反馈
见上述缺点。
评分：4：可以，但还不够好—拒稿
置信度：4：审稿人比较确信，但不能绝对确定该评价正确
底部的 **“Add: Author Response”** 是评审系统中的回复按钮，不属于审稿意见本身。

2. 动机分析所使用的具体模型不明确(Figure 1 和公式（1）—（2）到底基于哪个 VLN 模型；)

在引言中的经验分析部分，即“Motivating Observations”，论文基于逐层分析提出了两个核心现象。然而，论文没有说明 Figure 1 和公式（1）—（2）具体使用了哪个 VLN 模型。

这两个现象，即视觉衰减和多峰敏感性，是否在不同 VLN backbone 上都普遍成立？作者应明确说明实验设置，并在多个架构上进行初步分析，以支持这些现象具有普遍性。

- **Uni-NaVid：EVA-CLIP + Vicuna-7B（LLaMA-1）**
- **StreamVLN：LLaVA-Video-7B（Qwen2）（SigLIP + Llama-2-7B）**
- **GA-VLN：LLaVA-Video-7B（SigLIP + Llama-2-7B）（Qwen2）+ VGGT 几何分支**

其实对应的主干就是LLaVA-Video-7B-Qwen2上 语言主干是Qwen2-7B

2. 视觉扰动的方法和强度没有明确描述(视觉扰动的具体类型、幅度和选择依据；)

在“Visual Information Attenuation”部分，作者引入了一个受到扰动的视觉观察，用于测量逐层敏感性。然而，论文没有明确说明该扰动的具体方法和强度。

具体而言：

a) 使用了哪种扰动技术？例如高斯噪声、将视频帧置黑、特征级 masking，还是语义图像修改？

b) 扰动幅度是如何确定的？

c) 当改变视觉扰动的强度或类型时，观察到的衰减趋势是否仍然一致？

提供这些细节对于保证实验可复现性、验证经验结论的可靠性非常重要。

3. 早期层的余弦相似度仍然较高，需要进一步解释 (还是需要去解释视觉信息衰弱的这个点)

如公式（1）和 Figure 1（c）（或“Visual Information Attenuation”部分）所示，作者测量了由干净视觉信息和扰动视觉信息产生的隐藏状态之间的余弦相似度。

从理论上讲，较强的视觉扰动应该使早期 decoder layer 产生明显不同的视觉表示，从而导致较低的余弦相似度。然而，Figure 1 显示，即使在非常早的层，余弦相似度仍然相当高。

作者应详细解释：为什么早期层的表示在受到视觉扰动后仍然保持较高相似度？在这一背景下，什么程度的相似度下降才可以被认为是“显著下降”？

4. 为什么使用 SPL 而不是 SR 或 NE？（补充实验数据，但是也还是需要解释清楚视觉信息减弱的问题）

在“Layer-wise Visual Impact”部分，单层视觉注入实验使用 SPL 来评估性能变化。SPL 虽然是标准的 VLN 指标，但为什么在这一诊断性干预实验中选择 SPL，而不是 Success Rate（SR）或 Navigation Error（NE）？

为了确保结论更加稳健，论文应提供 SR 和 NE 的对应逐层分析图，以确认视觉强化究竟是直接改善了目标到达能力，还是主要影响了路径效率。

5. 层间隔、层预算和阈值缺乏详细消融（补充一个消融实验）

在“Gated Visual Adapter”部分，作者假设新注入的视觉特征需要经过若干后续 decoder layer 才能被吸收和整合，然后才适合进行下一次注入。这一假设构成了最小层间隔约束的动机。

虽然 Table 4 表明移除 separation loss 会导致性能下降，但论文缺少对关键参数的详细消融实验：

a) 模型对层间隔具体取值的敏感性如何？

b) layer budget 会如何影响整体性能以及计算开销之间的权衡？

c) 阈值 τ 的影响是什么？

此外，虽然 Table 1 在三个模型上评估了 LAVR，即 Uni-NaVid、StreamVLN 和 GA-VLN，但仍建议作者在更多近期的或更大规模的 VLN/VLA 模型上进行评估，例如 NaVILA 或 InternVL-N1。(补充模型)

NaVILA

= VILA-1.5-8B

= Llama 3 8B + SigLIP

- 视频/导航微调
- 机器人低层 locomotion policy

InternVLA-N1

= Qwen2.5-VL-7B

- 导航规划与像素目标 grounding
- System 1 / System 2 双系统控制

推荐意见说明

论文将深层对视觉扰动的敏感性降低解释为一种会损害导航能力的“视觉衰减”。然而，这种逐层行为也可以被理解为 Transformer decoder 学习到的一种自然功能分工：

- 早期到中间层可能负责处理和提取视觉观察；

- 更深层可能负责将多模态表示整合为抽象的高层动作决策。

因此，仅仅证明深层对扰动输入更加不敏感，并不能直接证明“视觉衰减”是限制导航能力的缺陷。

作者需要加强逻辑论证，并提供更具体的理论或经验依据，以说明为什么将视觉特征重新注入中间层是在解决真实的失败模式，而不是将不自然的视觉条件强行加入主要负责决策的层。

AI review

AI Review

AI Review by AI Reviewer ( ) 27 Jul 2026, 19:59 (modified: 24 Oct 2026, 20:28)

Program Chairs, AI Reviewer, Area Chairs, Senior Program Committee, Authors, Program Committee Submitted Revisions

Review:

Title: Layer-Adaptive Visual Reinforcement for Vision-Language Navigation

Synopsis of the paper

The paper studies how visual evidence influences successive decoder layers in continuous vision-language navigation agents. It introduces LAVR, which combines learned layer preferences with state-dependent representation discrepancies to reinject current-view features at sparse, separated layers. The mechanism is integrated into several host architectures and evaluated on two continuous-navigation benchmarks.

Summary of Review

Table 1 shows consistent paired navigation improvements across three host architectures and two benchmarks. However, Table 3 shows that the variant without Injection Strength Estimation already obtains most of the full method's headline gain, while the small remaining margin has no reported uncertainty. The motivating diagnostics also demonstrate non-monotonic visual sensitivity rather than the claimed progressive attenuation. Together with incomplete specification of the training-time selection rule and missing equal-budget controls, the evidence does not yet attribute the improvements to the complete adaptive mechanism.

Strengths

- **The host-controlled experimental design tests architectural applicability.** Table 1 evaluates each of Uni-NaVid, StreamVLN, and GA-VLN both with and without LAVR on R2R-CE and RxR-CE. This paired design reduces dependence on comparisons between differently trained navigation systems.
- **The evaluation uses established closed-loop navigation protocols.** The Experimental Setup reports NE, OSR, SR, and SPL on val-unseen splits. These metrics jointly capture goal proximity, route-level reachability, stopping success, and path efficiency, making the evaluation relevant to policy behavior rather than offline prediction alone.
- **The intervention has a limited optimization and deployment footprint.** The Implementation Details freeze the language and visual backbones, train a shared projector and layer scalars, and report (1.05\times) inference cost. This addresses the practically relevant setting of modifying decoder behavior without full host-model fine-tuning.

Weaknesses

- **The paper's own ablation does not support ISE as a material source of the headline improvement.** For reproduced GA-VLN, Table 1 reports an SPL increase from (55.21) to (58.68), while Table 3's "w/o ISE" variant reaches (58.26): (3.05) of the full (3.47)-point gain, or approximately (88%), is already present without ISE. The remaining (0.42)-point margin has no deviation or confidence interval despite being averaged over three runs, undercutting the claim that necessity and injection-strength signals provide demonstrated complementary benefits.
- **The central "progressive attenuation" premise is not established by the proposed diagnostics.** Equations (1)–(2) measure sensitivity to an unspecified perturbation rather than retained task-relevant information, and Figure 1(c) shows sensitivity increasing through early and middle depth before declining. The evidence supports reduced late-layer sensitivity relative to middle layers, not progressive information loss from input to output; interpreting it additionally requires the perturbation construction and comparable accuracy of the layer-wise action probes.
- **The novelty is narrower than the positioning indicates.** MemVR conditionally reinjects visual tokens into an intermediate FFN under model uncertainty, while AIR selectively integrates hidden-state-aligned visual evidence into feed-forward layers (Zou et al., 2025; Zhu et al., 2026); neither work is cited. LAVR's distinct contribution is therefore the VLN-specific, budgeted, separation-constrained layer policy rather than adaptive decoder-stage visual reinforcement broadly.
- **The experiments do not isolate adaptive layer selection from generic residual injection.** Tables 2–4 omit equal-budget random, fixed, uniformly spaced, dense Stage-I, and oracle layer-set controls; moreover, Table 2 changes injected content while keeping LAVR's locations fixed. Gaussian noise and shuffled features still improve SPL by (1.49) and (1.57) points over no reinforcement, respectively, so a substantial portion of the (3.47)-point full gain may arise from residual perturbation, projector training, or regularization rather than visually informed selection.
- **The training-time forward mechanism is not fully specified.** Equations (7)–(9) use hard thresholding and exclusion through (z_l), whereas the Implementation Details state that both operations occur only at inference without defining the Stage-II soft forward rule. Furthermore, (d_l) affects selection through (q_l=m_ld_l) but not the residual magnitude in Eq. (9), contrary to its description as "injection strength," preventing verification of the policy actually trained for Tables 1–4.
- **The main improvements lack uncertainty estimates.** Table 1 reports paired SPL gains of (2.1)–(3.47) points on R2R-CE and (1.4)–(1.8) points on RxR-CE without multiple-seed statistics, deviations, or confidence intervals. These incremental margins are consistently positive, but their repeatability cannot be assessed from the reported results.

Suggestions for Improvement

- **A failure-stratified evaluation would connect the intervention to VLN behavior.** Reporting results by path length, instruction language, stopping error, and baseline-success category would clarify whether reinforcement primarily improves visual grounding, long-horizon planning, or action termination.
- **A cross-model or cross-dataset reuse experiment would distinguish transfer from repeated adaptation.** Reusing learned layer preferences or the shared projector without retraining would test whether the discovered depth structure transfers rather than only whether LAVR can be separately fitted to different hosts.
- **Selection behavior could be related to observable decision conditions.** Correlating Figure 3's selections with action entropy, visual ambiguity, landmark references, or replanning events would show whether state-dependent choices correspond to interpretable navigation demands.

Additional Details and Minor Issues

- The Motivating Observations text cites Figure 1(b) for attenuation and Figure 1(c) for layer-wise intervention; the corresponding panels are Figure 1(c) and Figure 1(d).
- Equation (10) regularizes all (L) layers although Eq. (7) permits only (l\leq20); Figure 1(d)'s host and protocol are also not identified before this absolute cutoff is applied across architectures.
- Stage I says the frozen backbone "gradually adapt[s]," although only the projector and resulting activations can adapt.
- The Baselines paragraph claims comparisons with modular and 3D agents, but Table 1 contains only three paired host configurations.
- The best SR is (64.05) on R2R-CE and (56.9) on RxR-CE; wording about "reliable" decisions and robustness should reflect these absolute levels and the clean val-unseen protocol.

References

- Zou, X., Wang, Y., Yan, Y., Lyu, Y., Zheng, K., Huang, S., Chen, J., Jiang, P., Liu, J., Tang, C., & Hu, X. (2025). Look twice before you answer: Memory-space visual retracing for hallucination mitigation in multimodal large language models. *Proceedings of the 42nd International Conference on Machine Learning, 267*, 80873–80899. (proceedings.mlr.press)
- Zhu, X., Zhao, K., Yi, L., Wang, S., Wang, Z., Zhu, B., Zhang, H., & He, X. (2026). Look carefully: Adaptive visual reinforcements in multimodal large language models for hallucination mitigation. *International Conference on Learning Representations 2026*. (proceedings.iclr.cc)

Add: **Author Response**

代码块

```
1  AI 评审 2026 年 7 月 27 日 19:59（修改时间：2026 年 10 月 24 日 20:28） 收件对象：程序主席、AI 评审员、领域主席、高级程序委员会、作者、程序委员会
```

评审标题：Layer-Adaptive Visual Reinforcement for Vision-Language Navigation（面向视觉语言导航的层自适应视觉强化）

论文概述（Synopsis of the paper）

本文研究证据引导如何在连续视觉语言导航智能体中影响解码器各层。文章提出 LAVR，结合可学习的层偏好与表征差异，在稀疏、相互隔离的层级上重新注入视觉特征。该机制可以嵌入多种宿主架构，并在两个连续导航基准数据集上完成评测。

评审总结（Summary of Review）

在三种宿主架构、两个基准任务上，配对实验均展现出稳定的导航性能提升。但表 3 表明：去掉注入强度估计（ISE）的变体，就已经可以达到本文主方法的核心指标；并且这部分小幅增益，没有经过重复实验验证。文章的动机诊断实验同时表明，性能增益并非单调变化，和文中宣称的渐进式视觉衰减不符；再加上训练时机选择规则、分桶控制等细节描述不完善，现有证据**不足以证明 ISE 是自适应机制性能提升的核心来源**。

优点（Strengths）

宿主对照实验验证架构通用性：表 1 分别在 Uni-Nav、StreamVLN、GA-VLN 上，对比开启 / 关闭 LAVR 在 R2R-CE 与 RxR 数据集上的效果。这种配对设计，排除了不同训练导航系统之间的依赖干扰。

评测采用成熟闭环导航协议：实验报告 val-unseen 划分集上的 NE、OSR、SR、SPL 指标。这些指标综合刻画目标接近程度、路线可复现性、停止精度、路径效率，能够评估智能体真实行为，而不只是离线预测效果。

干预方案经过优化，部署开销低：实现策略为冻结语言、视觉主干，单独训练共享投影器与层缩放系数，推理开销仅增加 1.05 倍。这个方案解决了直接修改解码器全层带来的高昂推理成本问题。

缺点（Weaknesses）

论文消融实验**无法证明 ISE 是核心贡献模块**：以复现的 GA-VLN 结果为例，表 1 中 SPL 从 55.21 提升至 58.68；去掉 ISE 的变体 SPL 达到 58.26，3.47 点总提升里有约 88% 的增益在没有 ISE 时就已经存在；剩余仅 0.42 的提升幅度，没有偏差、置信区间支撑。诊断实验也说明，阈值和注入强度的选择会极大改变性能收益。

核心的**“渐进注意力”前提没有被诊断实验证实**：图 1（2）的扰动敏感性实验显示，经过扰动的表征依然保留任务相关信息；图 1（c）的结果显示，敏感度沿着浅层到中层逐步下降。现有证据只能说明高层对中层表征敏感度下降，**不存在从底层向上传递的渐进信息流**；换句话说，扰动实验只证明表征可分解、可对比，而不是作者宣称的层级自适应特性。

论文创新范围比摘要里表述的更窄：MenvR 方法在不确定条件下，会在中间 FFN 层有条件地拒绝视觉 token；Air 方法选择性把隐层状态的视觉证据送入前向网络（Zou 等人，2025；Zhu 等人，2025）；两篇相关工作都没有被引用。LAVR 的分布控制，本质是在 VLN 场景下做预算约束、隔离层级的策略，是把已有思路迁移到解码器层的视觉增强，不属于全新范式。

实验没有把**自适应层级选择**和通用残差注入的效果分离开：表 2、4 设置了等量分桶随机、固定、均匀间隔、密度固定、oracle 选层等对照；另外表 2 修改注入位置时，高斯噪声、打乱特征的基线依然可以带来 1.49、1.57 点的 SPL 提升。也就是说，3.47 点总增益里，很大一部分可能仅仅来自残差扰动、投影操作、正则化效果，而不是视觉层面的自适应选择。

训练前向传播机制描述不完整：公式（7）-（9）使用硬阈值与式（2J）的排除操作；但实现细节写明，这些操作在 Stage-1 前向推理时独立运行。另外，式（J）仅调整\(q^{(l,m)}\)来影响选择，**不修改公式 Eq.(9) 里的残差幅值**，和文中“注入强度”的描述冲突，导致表 1–4 的结论验证缺少可靠策略校验。

主要性能提升存在统计不确定性：表 1 报告 R2R-CE 上 SPL 提升 2.1–3.47 点，RxR-CE 上提升 1.4–1.8 点；但是没有提供多次独立实验的均值、方差或者置信区间。这些增量虽然看起来正向，但是可复现性会被审稿人质疑。

改进建议（Suggestions for Improvement）

增加失败案例分层评估，把干预效果和 VLN 行为绑定：按路径长度、指令语言、停止错误、基线是否成功进行分组汇报结果，能够清晰说明改进到底是提升了长距离规划、导航能力，还是终止判断能力。

增加跨模型 / 跨数据集实验，区分迁移能力和重复适配：固定学到的层偏好、共享投影器，不做重新训练，测试这套深度选择规则是否能迁移；而不只是证明 LAVR 可以单独适配不同宿主模型。

层级选择行为可以关联可观测的决策条件：把图 3 的 LAVR 选择结果，和动作熵、视觉歧义、地标参考、重规划事件做相关性分析，展示什么时候会触发层级选择，形成可解释的导航决策依据。

补充细节与次要问题（Additional Details and Minor Issues）

用于动机论证的可视化子图：图 1（b）为衰减效果、图 1（c）为层级干预；对应的子图编号是图 1（c）和图 1（d）。

公式（10）声明作用于全部层，但公式（7）仅在\(l\neq20\)时生效；图 1（d）的热图、协议在这个全局约束生效前没有标注。

消融里描述“分层逐步生效”，但只有投影器与选择器模块可以自适应调整。

基线对比采用模块化、30 智能体设置，但表 1 只包含三组宿主架构结果。

报告的最优 SR（R2R-CE 上 64.05，RxR-CE 上 56.99）标注为“可靠结果”，但鲁棒性评估应当同时给出绝对值、以及 val-unseen 干净基准下的基线。

参考文献（References）

Zou, X., Wang, Y., Yan, Y., Lyu, Y., Zheng, K., Huang, S., Chen, J., Jiang, P., Liu, J., Tang, C., & Hu, X. (2025). Look twice before you answer: Memory-space visual retracing for hallucination mitigation in multimodal large language models. *Proceedings of the 42nd International Conference on Machine Learning*.

Zhu, X., Zhao, K., Li, Y., Wang, S., Zhang, Z., Zhu, B., Zhang, H., & He, X. (2026). Look carefully: Adaptive visual reinforcements in multimodal large language models for hallucination mitigation. *International Conference on Learning Representations (ICLR)*.

缺点（Weaknesses）

1. 论文消融实验**无法证明 ISE 是核心贡献模块**：以复现的 GA-VLN 结果为例，表 1 中 SPL 从 55.21 提升至 58.68；去掉 ISE 的变体 SPL 达到 58.26，3.47 点总提升里有约 88% 的增益在没有 ISE 时就已经存在；剩余仅 0.42 的提升幅度，没有偏差、置信区间支撑。诊断实验也说明，阈值和注入强度的选择会极大改变性能收益。
2. 核心的**“渐进注意力” 前提没有被诊断实验证实**：图 1 (2) 的扰动敏感性实验显示，经过扰动的表征依然保留任务相关信息；图 1 (c) 的结果显示，敏感度沿着浅层到中层逐步下降。现有证据只能说明高层对中层表征敏感度下降，**不存在从底层向上传递的渐进信息流**；换句话说，扰动实验只证明表征可分解、可对比，而不是作者宣称的层级自适应特性。
3. 论文创新范围比摘要里表述的更窄：MenvR 方法在不确定条件下，会在中间 FFN 层有条件地拒绝视觉 token；Air 方法选择性把隐层状态的视觉证据送入前向网络（Zou 等人，2025；Zhu 等人，2025）；两篇相关工作都没有被引用。LAVR 的分布控制，本质是在 VLN 场景下做预算约束、隔离层级的策略，是把已有思路迁移到解码器层的视觉增强，不属于全新范式。
4. 实验没有把**自适应层级选择**和通用残差注入的效果分离开：表 2、4 设置了等量分桶随机、固定、均匀间隔、密度固定、oracle 选层等对照；另外表 2 修改注入位置时，高斯噪声、打乱特征的基线依然可以带来 1.49、1.57 点的 SPL 提升。也就是说，3.47 点总增益里，很大一部分可能仅仅来自残差扰动、投影操作、正则化效果，而不是视觉层面的自适应选择。
5. 训练前向传播机制描述不完整：公式 (7)–(9) 使用硬阈值与式 (2J) 的排除操作；但实现细节写明，这些操作在 Stage-1 前向推理时独立运行。另外，式 (J) 仅调整 $q^{(l,m)}$ 来影响选择，**不修改公式 Eq.(9) 里的残差幅值**，和文中 “注入强度” 的描述冲突，导致表 1–4 的结论验证缺少可靠策略校验。
6. 主要性能提升存在统计不确定性：表 1 报告 R2R-CE 上 SPL 提升 2.1–3.47 点，RxR-CE 上提升 1.4–1.8 点；但是没有提供多次独立实验的均值、方差或者置信区间。这些增量虽然看起来正向，但是可复现性会被审稿人质疑。

改进建议（Suggestions for Improvement）

1. 增加失败案例分层评估，把干预效果和 VLN 行为绑定：按路径长度、指令语言、停止错误、基线是否成功进行分组汇报结果，能够清晰说明改进到底是提升了长距离规划、导航能力，还是终止判断能力。
2. 增加跨模型 / 跨数据集实验，区分迁移能力和重复适配：固定学到的层偏好、共享投影器，不做重新训练，测试这套深度选择规则是否能迁移；而不只是证明 LAVR 可以单独适配不同宿主模型。
3. 层级选择行为可以关联可观测的决策条件：把图 3 的 LAVR 选择结果，和动作熵、视觉歧义、地标参考、重规划事件做相关性分析，展示什么时候会触发层级选择，形成可解释的导航决策依据。

补充细节与次要问题（Additional Details and Minor Issues）

1. 用于动机论证的可视化子图：图 1 (b) 为衰减效果、图 1 (c) 为层级干预；对应的子图编号是图 1 (c) 和图 1 (d)。
2. 公式 (10) 声明作用于全部层，但公式 (7) 仅在 $l \neq 20$ 时生效；图 1 (d) 的热图、协议在这个全局约束生效前没有标注。
3. 消融里描述 “分层逐步生效”，但只有投影器与选择器模块可以自适应调整。
4. 基线对比采用模块化、30 智能体设置，但表 1 只包含三组宿主架构结果。
5. 报告的最优 SR（R2R-CE 上 64.05，RxR-CE 上 56.99）标注为 “可靠结果”，但鲁棒性评估应当同时给出绝对值、以及 val-unseen 干净基准下的基线。

当务之急：

Motivation的争议：

有四个审稿人均对视觉信息衰减提出来异议，均是认为我们的做法是测量模型对于视觉信息的视觉扰动的敏感性，

1. 你的论文实际上做了什么？

你的实验流程是：

1. 给模型输入原始视觉观察 v；
2. 构造一个扰动后的视觉观察 $\tilde{v}$；
3. 保持指令、导航历史和候选动作不变；
4. 比较不同 decoder layer 中两种输入产生的结果。

你测了两个量。

对于隐藏状态，你计算：

$$C_l^{hid} = \frac{1}{N} \sum_i \cos(h_{l,i}(v, x), h_{l,i}(\tilde{v}, x))$$

如果余弦相似度越高，说明原始输入和扰动输入在该层产生的隐藏状态越相似，也就是该层对这次视觉扰动越不敏感。

对于动作分布，你使用 action probe 得到：

$$S_l^{act} = D_{KL}\left(\pi_l(\cdot|v, x) \| \pi_l(\cdot|\tilde{v}, x)\right)$$

如果 KL 越低，说明原始视觉和扰动视觉对该层的动作预测影响越接近。

你的观察是：

- 早期层：原始视觉和扰动视觉造成的差异较大；
- 深层：隐藏状态越来越相似，action-probe 输出差异越来越小。

所以，你的实验直接测到的是：

> **随着 decoder 深度增加，模型对所选视觉扰动的表示敏感性和动作敏感性下降。**

逐层的采样出来的最大的概率 token的index 计算概率差值 比较加噪和不加噪的概率的差值

审稿人的想法归纳：

第一种可能：视觉信息被抽象化，而不是丢失

Transformer decoder 的深层本来就可能把视觉信息转化成：

- 与语言指令融合后的表示；
- 与导航历史融合后的表示；
- 与候选动作相关的抽象表示；
- 更接近最终决策的高层语义。

这种情况下，深层表示可能已经不再接近原始视觉 embedding，但仍然保留了有效的视觉信息。

第二种可能：模型学到了对扰动的鲁棒性

如果扰动改变的是某些不重要的像素、局部特征或视觉细节，模型在深层对它不敏感，可能说明模型学会了忽略无关变化。

这可以是好的不变性，而不一定是视觉遗忘。

aVNe 因此追问：

- 你到底使用了什么扰动?
- 扰动强度多大?
- 如果改变扰动强度，趋势是否仍然存在?
- 如果换另一种扰动，趋势是否仍然存在?

如果扰动本身不够强，或者主要破坏了非任务相关信息，那么敏感性下降就很难解释成视觉信息丢失。

第三种可能：余弦相似度并没有只测视觉信息

你的 C_l^{hid} 比较的是完整隐藏状态之间的相似度。隐藏状态中还包含：

- 指令信息；
- 导航历史；
- 候选动作信息；
- 语言和视觉融合信息。

即使视觉部分发生了变化，其他共享成分也可能让整体隐藏状态保持较高余弦相似度。

因此，较高的余弦相似度不一定表示视觉信息还在，也不一定表示视觉信息丢失。

第四种可能：action probe 的能力随层变化

你在每一层接 action probe，然后比较两个输入产生的动作分布。但如果不同层的 probe 能力、训练稳定性或预测准确率不同，那么 KL 下降可能来自：

- 该层本身的信息变化；
- probe 没有能力解码该层中的视觉信息；
- 两个输入都被 probe 映射成相似的动作分布。

因此，action-probe 的结果需要说明：

- probe 如何训练；
- 每层 probe 的预测性能是否相当；
- KL 的下降是否与真实导航指标关联。

回复方案一：按照审稿人的建议来减弱用词表述？？

层级敏感性不同+ 单层注入效果不同---》》需要层级自适应干预

（我们观察到，随着 decoder 深度增加，模型在表示层面和 action-probe 层面对所选视觉扰动的敏感性都会下降。这说明后部 decoder layer 对输入层面的视觉变化响应较弱，并由此启发我们进行逐层视觉干预。我们不将这一趋势单独解释为任务相关视觉信息已经确定性丢失的证据。）

> 深层 decoder 对所选视觉扰动的表示敏感性和动作敏感性降低。

但还不能单独说：

> 深层 decoder 丢失了任务相关的视觉信息。
> 不要只用 cosine similarity 的变化解释视觉信息；

要加入任务相关的 hidden-state probe 和因果干预。

实验一：借鉴 VIP/TVI，做"视觉输入 vs 视觉移除"的逐层对比

你提到的视觉-文本融合方法，主要是另一篇论文：

Understanding Language Prior of LVLMs by Contrasting Chain-of-Embedding

它的核心做法是比较：

$$Z_l^{vis} = f_l(v, x)$$

和

$$Z_l^{blind} = f_l(\varnothing, x)$$

也就是：

- 正常视觉 + 文本；
- 去掉视觉 + 相同文本。

然后计算不同层之间的表示距离：

$$D_l^{blind} = d(Z_l^{vis}, Z_l^{blind})$$

这可以迁移到你的 VLN 模型中。

你可以构造四种输入：

1. 正常视觉观察 v；
2. 视觉被移除或替换为空视觉的输入 $\varnothing$；
3. 任务相关的反事实视觉 v^{cf}；
4. 与任务无关的 nuisance perturbation。

然后画出：

$$D_l^{blind} = d(h_l(v, x), h_l(\varnothing, x))$$

以及：

$$D_l^{cf} = d(h_l(v, x), h_l(v^{cf}, x))$$

但这里要注意：

- 如果 D_l^{blind} 很大，说明视觉影响了表示；
- 如果 D_l^{blind} 在深层变小，说明视觉输入对深层表示的直接影响减弱；
- 但它本身仍然不能证明视觉信息丢失。

所以这个实验应当作为"视觉影响曲线"，而不是单独作为"信息丢失证明"。

实验二：训练逐层的任务相关视觉 probe

这是最重要的一步。

你需要定义一些明确的、必须依赖当前视觉观察才能判断的目标，例如：

- oracle next action：前进、左转、右转、停止；
- 当前视野是否包含正确地标；
- 目标方向；
- 可通行方向；
- 是否已经到达目标区域；
- 当前视觉是否支持 stop decision。

记这些任务相关视觉标签为 y^{vis}。

然后对每个 decoder layer 的 hidden state h_l 训练同样容量的 probe：

$$g_l(h_l) \to y^{vis}$$

例如使用固定结构的：

- linear probe；
- logistic regression；
- 小型 MLP。

关键是所有层使用相同的 probe 容量、相同的数据划分和相同的训练预算。

你最终要画：

$$\text{Probe Accuracy}/\text{AUROC}_l$$

如果视觉信息真的在深层衰减，应当看到：

- 早期或中间层可以较好地解码任务相关视觉变量；
- 深层的视觉任务 probe 性能下降；
- 这种下降在 held-out scene、held-out route 或 held-out instruction 上仍然存在；
- text-only / blind condition 接近随机水平。

更强的做法是使用视觉反事实对：

$$(v^+, x), (v^-, x)$$

其中：

- instruction 和 navigation history 相同；
- 两个视觉观察来自同一状态或匹配状态；
- 正确动作不同，例如一个需要左转，一个需要右转。

然后让 probe 只判断视觉条件对应的 action label。

这样可以减少文本和历史信息的干扰。

如果要把这个事情给讲清楚的话，我感觉可能就是一篇文章？？？ 就是专门分析VLN中不同层的视觉信息对导航结果的一个影响？

如果需要补充实验的话，我觉得需要去参考这篇文章：

因为我注意到

https://arxiv.org/pdf/2606.17389
arxiv.org

https://arxiv.org/pdf/2509.23050
arxiv.org

Hidden-state probe：从不同层隐藏状态中预测任务标签；

Layer-wise logit lens：观察不同层的决策信息何时出现；

Causal ablation/intervention：干预内部表示，再观察输出变化。

第二优先级： 解决 ISE 的公式和术语问题（两个人提出来，HLC3、dNwp）

这个问题确实需要单独理清，因为 HLC3 指出的不是普通的"实验不够多"，而是：

> **ISE 的名字、公式定义和它在实际前向传播中的作用没有对齐。**

你当前方法中的四个量分别是：

$$m_l = \sigma(s_l)$$

表示第 l 层的**学习型视觉强化必要性分数**。

$$d_l = \frac{\|R^V - H_l^V\|_F}{\|R^V\|_F + \|H_l^V\|_F + \epsilon}$$

表示当前层视觉表示 H_l^V 与原始投影视觉特征 R^V 之间的**表示差异**。

$$q_l = m_l d_l$$

表示综合考虑层必要性和当前表示差异后的**层选择分数**。

$$z_l = \mathbb{I}[q_l > \tau \ \wedge \ \text{满足层约束}]$$

表示最终是否在该层进行注入。

但真正的残差注入公式是：

$$\tilde{H}_l^V = H_l^V + z_l m_l R^V$$

所以当前机制中：

- m_l 影响是否选层，也影响注入幅度；
- d_l 影响 q_l，从而影响是否选层；
- d_l 不直接出现在注入幅度中；
- q_l 也不直接出现在注入幅度中。

这就是审稿人看到的核心矛盾。

你论文文字说的是：

> ISE estimates the injection strength.

但公式真正实现的是：

> ISE estimates a discrepancy signal that helps decide whether to inject.

m_l：一个**全局的层级先验**，表示某一层通常有多值得进行视觉强化；

d_l：一个**当前样本相关的视觉表示偏差**，表示当前层的视觉状态与当前视图特征偏离了多少；

$q_l = m_l d_l$：一个**样本-层级联合干预优先级**；

z_l：最终的稀疏选择结果；

m_l：当前实际使用的残差注入权重。

VNA 提供层级先验，ISE 提供当前样本的偏差信号，二者共同决定在哪些层进行视觉重条件化；实际注入幅度由学习到的层级系数控制